


전체 프로세스



시계열 데이터 요소


기준 타임스탬프 (t) 를 중심으로 시계열 데이터의 주요 요소를 정의합니다.



i 모든 요소는 기준 타임스탬프 t 를 기준으로 정의되며, 예측은 t 이후의 미래 구간($t+1 \sim t+H$)을 대상으로 수행됩니다.

시계열 데이터의 주요 패턴

하나의 시계열 데이터는 Trend, Seasonality, Cycle, Noise, Event와 같은 주요 패턴들의 합성으로 구성됩니다.



산업계에서 선형모델(Linear)을 많이 쓰는 이유

너무 복잡한 것보다는 결국 단순한 것이 가장 좋다.



해석과 이해가 쉽다

모델의 결과가 입력 변수의 선형 조합으로 표현되어, 어떤 변수가 결과에 어떤 영향을 미치는지 직관적으로 이해할 수 있습니다.



계산이 빠르고 효율적이다

학습과 예측이 매우 빠르며, 대규모 데이터와 실시간 시스템에서도 안정적으로 사용할 수 있습니다.



안정적이고 과적합 위험이 낮다


모델이 단순하기 때문에 새로운 데이터에 대한 일반화 성능이 좋고, 과적합(overfitting) 위험이 적습니다.




실무에서 충분히 효과적이다

현업의 많은 문제는 선형 관계로도 충분히 설명 가능하며, 복잡한 모델 대비 비용 대비 성능(가성비)이 높습니다.

단순하지만 강력한 설명력



실무 활용 예시



결국, 단순한 모델이 비즈니스 의사결정을 가장 빠르고 안전하게 만듭니다.

그럼에도 불구하고 내가 Diffusion model을 관심 있게 보는 이유?

✓ 1. 잔차(Residual) 학습에 최적화된 구조

Diffusion model은 noise를 점진적으로 예측(denosing)하는 방식으로 학습
→ 이는 잔차(입력과 출력의 차이)를 학습하는 residual block과 본질적으로 유사

✓ 2. U-Net 기반 아키텍처의 skip connection

Encoder-Decoder 구조에서 skip connection을 통해 잔차 정보를 효과적으로 전달하고 복원에 활용

✓ 3. 안정적인 학습 동역학

Diffusion process의 잠진적 noise 추가/제거 과정은 잔차 학습의 안정성(stability)과 잘 맞음
(vanishing/exploding gradient 완화)

✓ 4. 다양한 변형과 확장성

Conditional Diffusion, Latent Diffusion, Score-based model 등 다양한 확장 구조에서도
잔차 학습 기법을 쉽게 접목 가능

✓ 5. 실증적 성능 우수성


이미지 생성, super-resolution, inpainting 등에서 잔차 기반 모델들이 SOTA 성능을 달성하고 있음



인터넷에서 찾은 관련 내용

- Diffusion models can be viewed as a way to learn the residual between noisy data and clean data. (Ho et al, Denoising Diffusion Probabilistic Models, NeurIPS 2020)
- The U-Net in diffusion models uses residual connections to propagate information across scales, which is crucial for learning the residual noise. (Rombach et al, High-Resolution Image Synthesis with Latent Diffusion Models, CVPR 2022)
- Residual learning in diffusion models helps stabilize training and improves sample quality. (Song et al, Score-Based Generative Modelling through Stochastic Differential Equations, ICLR 2021)

(출처: arXiv, Papers With Code, Liliu Wang's Blog 등)



(이미지 출처: <https://arxiv.org/abs/2006.11239>)

Residual Block in Diffusion U-Net (PyTorch 예시)

```
class ResidualBlock(nn.Module):
    def __init__(self, dim):
        super().__init__()
        self.block = nn.Sequential(
            nn.GroupNorm(32, dim),
            nn.SiLU(),
            nn.Conv2d(dim, dim, 3, padding=1),
            nn.GroupNorm(32, dim),
            nn.SiLU(),
            nn.Conv2d(dim, dim, 3, padding=1),
        )
    def forward(self, x):
        return x + self.block(x) # residual connection
```

(출처: <https://github.com/lucidrains/denoising-diffusion-pytorch>)

Diffusion Model 기반 잔차 모델 성과 예시

Task	모델	성과 (예시)
Image Generation	DDPM (Residual 기반)	FD 3.17 (CIFAR-10)
Super-Resolution	SR3 (Residual 기반)	PSNR 28.57 (ImageNet)
Inpainting	RePaint (Diffusion + Residual)	FD 4.86 (CelebA-HQ)

(출처: Papers With Code, arXiv:2006.11239, arXiv:2105.05233)

MAE만 사용하면 안 되고, R²도 함께 사용해야 하는 이유


MAE는 오차의 크기만 측정하지만, R²는 모델의 설명력을 평가합니다. 두 지표를 함께 사용해야 시계열 예측 모델을 정확하고 균형 있게 평가할 수 있습니다.

! MAE 단독 사용의 한계

- × 오차의 절대적 크기만 반영
데이터의 변동성(Scale)을 고려하지 못해 모델 성능을 왜곡할 수 있음
- × 설명력(모델이 데이터의 패턴을 얼마나 잘 설명하는가)을 평가하지 못함
단순 평균 모델보다 못한 모델도 MAE가 작을 수 있음
- × 과소적합(Underfit)이나 상수 모델(constant model)도 MAE만으로는 구분 어려움


결과: "오차는 작지만, 실제 패턴은 전혀 설명하지 못하는 모델"을 좋은 모델로 오인할 위험이 있음

예시 1. MAE는 작지만 R²는 낮은 경우 (과소적합/상수 모델)



평균값을 예측한 것과 다를 없어
데이터의 변동을 전혀 설명하지 못함

예시 2. MAE는 비슷하지만 R²는 높은 경우 (좋은 모델)



데이터의 변동 패턴을 잘 따라가며
설명력이 높음

✓ R²를 병행해야 하는 이유

- ✓ 모델의 설명력을 평가
데이터의 변동 등 모델이 설명하는 비율을 제공 (0~1, 1에 가까울수록 좋음)
- ✓ 모델 간 비교가 가능
서로 다른 스케일이나 데이터셋에서도 성능을 공정하게 비교
- ✓ 잘못된 모델을 걸러냄
MAE는 작아도 R²가 낮으면 모델이 패턴을 제대로 학습하지 못한 것

💡 MAE는 "얼마나 틀렸는가"를, R²는 "얼마나 잘 설명하는가"를 알려줍니다. 두 지표를 함께 사용해야 더 정확하고 신뢰할 수 있는 평가가 가능합니다.

$$\ast R^2 (\text{결정계수}) = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$